TecnoForms: digitalización asistida de formularios manuscritos

Trabajo final — Clasificación de Dígitos Manuscritos Fecha: 5 de noviembre de 2026

1. Problema y objetivo

TecnoForms procesa formularios de inscripción, pagos y solicitudes cuyo contenido numérico se escribe a mano. La transcripción manual consume tiempo y puede introducir errores. El objetivo es convertir la foto de un formulario en campos digitales revisables, reconocer sus dígitos mediante aprendizaje automático y generar análisis por tipo de respuesta.

Se propone un flujo asistido por una persona. La aplicación no autoriza pagos ni determina calificaciones o admisiones. Su resultado es una propuesta de transcripción que el usuario revisa y confirma.

2. Solución implementada

La aplicación web permite crear una cuenta e iniciar sesión, responder un cuestionario inicial y ver una guía para principiantes en el primer ingreso. En el segundo acceso esa guía ya no aparece automáticamente. Siempre se puede consultar desde Cómo funciona.

El usuario sube una foto JPG, PNG o WEBP. Tesseract intenta detectar líneas, rótulos y respuestas legibles. Para las respuestas numéricas manuscritas se seleccionan regiones sobre la imagen y se asigna un nombre de campo. El sistema segmenta dígitos, calcula características HOG y propone los números con SVM. Los campos resultantes son editables; pueden añadirse respuestas manuales. Se exige confirmar la revisión para guardar.

Los formularios quedan asociados a la cuenta, pueden exportarse a CSV y alimentan un panel de análisis. Las estadísticas agrupan respuestas por nombre de campo, muestran cantidad, media, mínimo y máximo, y excluyen respuestas no numéricas y nombres comunes de identificadores. No se suman notas con pagos ni edades con otros datos.

La interfaz incluye identidad gráfica original, colores lima/lila/rosa sobre fondo oscuro, desenfoque decorativo, letras de estilo graffiti, animación de escaneo, stickers, emojis y diálogos flotantes. El contenido conserva contraste y el diseño se adapta a pantallas pequeñas; se respeta la preferencia de movimiento reducido.

3. Metodología y datos

Benchmark académico: UCI Optical Recognition of Handwritten Digits, distribuido en scikit-learn. Contiene 1 797 imágenes de 8×8 y clases 0 a 9. Se normalizan las intensidades 0–16 a 0–1. Se verifican faltantes, duplicados y distribución. La partición estratificada reserva 360 imágenes para test y 1 437 para entrenamiento, con semilla 42.

Se comparan KNN (k=3,5), SVM RBF (C=1,10) y MLP (alpha=0.0001,0.001). GridSearchCV usa 3 pliegues estratificados y F1 macro dentro del entrenamiento. Se selecciona por validación y después se reporta test. No se ajustan parámetros usando test.

Motor de regiones: MNIST, imágenes de 28×28. Se muestrean 15 000 ejemplos oficiales de entrenamiento con semilla 42. Se separan 3 000 para validar C=2 y C=8; se elige C=2 y se reentrena con las 15 000 muestras. La evaluación final usa las 10 000 imágenes oficiales de test. HOG produce 324 características. Este

experimento se informa separado del benchmark UCI.

Datos ficticios: se generan 240 registros de formularios con cantidad de campos, calidad simulada y tiempo sintético. Una MLP adicional aprende una etiqueta ficticia de procesabilidad y se evalúa en test separado. La regresión lineal usa test separado para estimar tiempos; K-Means con escalado construye 3 grupos operativos. Son evidencias curriculares y no demuestran ahorros empresariales reales.

4. Preprocesamiento de imágenes

Se valida tamaño y resolución, aplica orientación EXIF y reduce la imagen manteniendo proporción. La aplicación ofrece giro manual. Las regiones numéricas se convierten a gris y se binarizan con Otsu. Se retiran fragmentos de líneas largas en los bordes; se detectan componentes conectados y se ordenan de izquierda a derecha. Cada recorte se escala conservando proporción, se coloca en una imagen de 28×28 y se centra por momentos de tinta; HOG transforma el patrón en características para SVM.

La calidad de captura es fundamental: hoja de frente, iluminación uniforme, buen enfoque y dígitos separados. No se implementó corrección automática de perspectiva. Trazos partidos o unidos pueden provocar segmentación incorrecta; letras y puntuación dentro de regiones numéricas pueden confundirse con números. Por eso la revisión siempre es obligatoria.

5. Red neuronal y funcionamiento interno

La MLP tiene 64 entradas, dos capas ocultas de 64 y 32 neuronas ReLU y salida de 10 clases softmax. Usa 6 570 parámetros, Adam, entropía cruzada multiclase, learning rate inicial de 0.001, regularización L2 y hasta 180 iteraciones. El cuaderno conserva advertencias de convergencia: alcanzar el máximo de iteraciones no demuestra convergencia y es un punto de mejora.

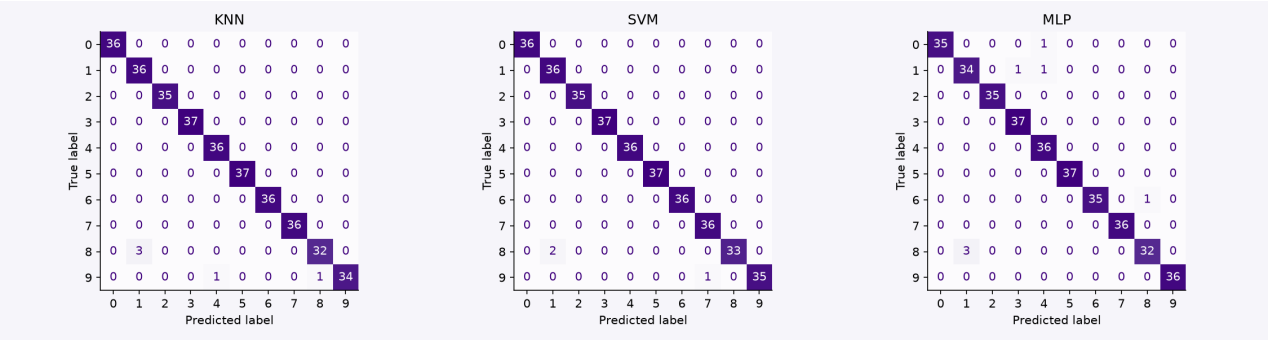
En propagación hacia adelante se calcula $z=W\cdot x+b$ y se aplica activación. Softmax normaliza la salida. La entropía cruzada penaliza discrepancias respecto a la etiqueta real; retropropagación obtiene gradientes y Adam actualiza los pesos. Validación y regularización ayudan a controlar sobreajuste. No se utiliza CNN; por tanto, el requisito condicional de capas convolucionales no corresponde a esta arquitectura. Una CNN queda como futura comparación con más datos del dominio.

6. Resultados medidos

Modelo	Exactitud test UCI
KNN	98.61%
SVM	99.17%
MLP	98.06%

SVM se seleccionó por el mayor F1 de validación. El motor HOG/SVM obtuvo **99.04% en MNIST test oficial**. Las precisiones macro, recall, F1, parámetros, matrices de confusión y clasificación por clase están en los JSON de `models/` y en el cuaderno ejecutado. Los gráficos muestran predicciones y etiquetas reales de ejemplos separados de test.

Estas cifras pertenecen a **dígitos aislados estandarizados**. No son la exactitud de digitalización de un formulario completo ni de una fotografía nueva. El sistema aún no tiene un test empresarial independiente de formularios reales. No se usa la puntuación del modelo como garantía de corrección.





7. Preguntas guía

1. ¿Qué desafíos producen la variabilidad de escritura y la calidad de imagen? Cambian tamaño, inclinación, presión y trazado entre personas. Dígitos similares (1/7, 3/8, 4/9) pueden confundirse. Sombras, desenfoque, tablas, manchas y perspectiva dificultan segmentar. Un error de segmentación puede dividir un número en dos o unir varios. Deben medirse por separado localización, transcripción y cadena completa.

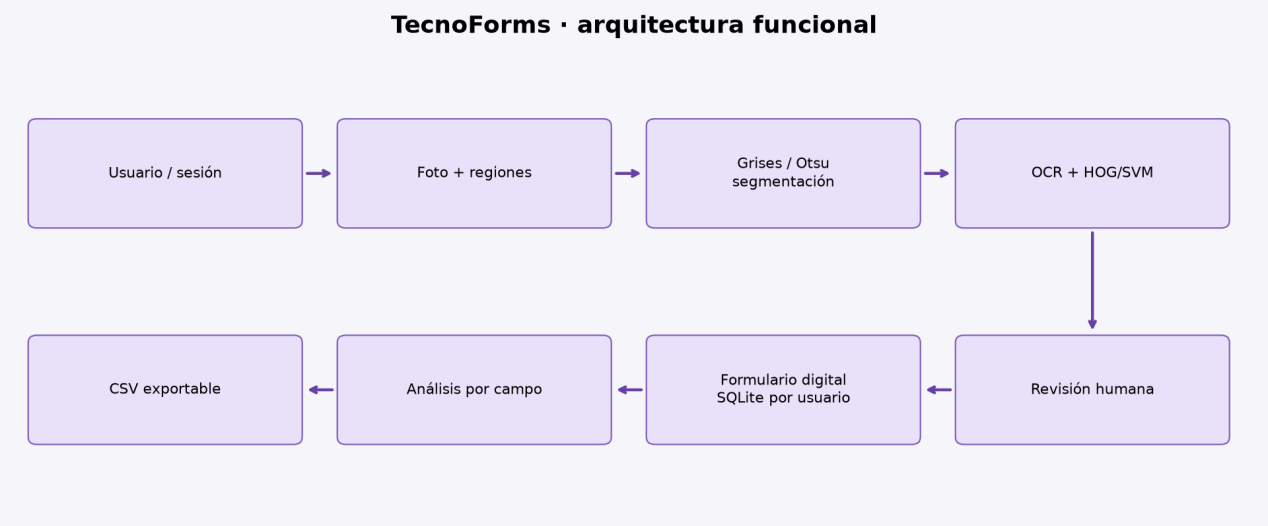
2. ¿Cómo afecta la elección de algoritmo? KNN es simple, depende de distancias y escala, y almacena ejemplos. SVM aprende fronteras no lineales y funciona bien con conjuntos moderados. MLP aprende características por pesos y requiere más cuidado con convergencia y regularización. En este experimento gana SVM por validación; eso no prueba superioridad universal. La elección debe considerar precisión por clase, tiempo y memoria.

3. ¿Qué preprocesamiento es más efectivo? Orientación, gris, binarización, supresión cuidadosa de líneas, recorte, conservación de proporción y centrado son útiles. Otsu funciona con iluminación uniforme; umbral adaptativo puede ayudar con sombras pero requiere validación. Un suavizado excesivo borra trazos finos. La corrección geométrica debe añadirse y probarse con fotos oblicuas.

4. ¿Qué métricas deben considerarse e interpretarse? Exactitud es la fracción total de aciertos. Precisión mide aciertos entre predicciones de una clase; recall, ejemplos recuperados de los reales; F1 equilibra ambos. La media macro evita que una clase abundante domine. La matriz localiza confusiones. En el producto deben añadirse exactitud por campo y formulario, tasa de correcciones, tiempo humano y cobertura de campos. La transcripción de un número completo puede fallar aunque la mayoría de sus dígitos sean correctos.

5. ¿Cómo mejorar si la precisión no es aceptable? Reunir fotos consentidas, distintas personas y dispositivos; etiquetar regiones; separar test por escritor/formulario; aumentar imágenes con sombras, ruido y geometría; probar CNN o HTR para texto libre; ajustar solo en validación; calibrar scores; incorporar revisión ante casos dudosos y versionar correcciones verificadas. Repetir evaluación independiente antes de sustituir un modelo.

8. Arquitectura, factibilidad y plan de validación



Flask recibe solicitudes, verifica sesión y token CSRF y consulta SQLite con parámetros. Cada formulario pertenece a un usuario. La fotografía se mantiene en memoria y no se conserva. El resultado revisado se guarda y el análisis se calcula en la interfaz. Render ejecuta un contenedor Docker con Tesseract, OpenCV y modelos entrenados.

La factibilidad técnica está demostrada por entrenamiento reproducible, métricas, código ejecutado y pruebas de integración. La factibilidad operativa se debe comprobar con un piloto: al menos 100 formularios nuevos, varios escritores, tres condiciones de luz y diferentes teléfonos. Dos personas deben verificar las etiquetas. Separar evaluación por escritor para evitar fuga de estilos. Reportar coincidencia exacta por campo/cadena, dígitos, tasa de corrección y tiempos mediano/p95. Definir criterios de aceptación con TecnoForms antes de medir; una meta futura nunca se presenta como resultado obtenido.

9. Seguridad, salud y ambiente

Se usan hashes de contraseñas, cookies HttpOnly/SameSite (Secure en Render), validación de archivos, límite de carga, CSRF autenticado, aislamiento de cuentas y neutralización de fórmulas peligrosas en CSV. No se publican archivos del curso, fotos privadas ni bases de usuarios en GitHub.

El plan gratuito de Render usa almacenamiento temporal: cuentas y formularios pueden perderse al reiniciar, suspender o desplegar. La interfaz lo advierte y permite exportar. Para operación permanente hace falta PostgreSQL o un disco persistente. Faltan recuperación de contraseña, verificación de correo y límites distribuidos de autenticación para uso productivo. El prototipo no debe alojar datos sensibles reales.

La captura debe hacerse con postura cómoda, buena iluminación y pausas visuales. Digitalizar evita reimpresiones, pero se deben eliminar copias temporales y evitar reentrenamientos innecesarios. Los archivos de prueba deben ser ficticios o contar con consentimiento.

10. Matriz de cumplimiento del entregable

Consideración o evidencia requerida	Implementación verificable
Propuesta de solución fundamentada en el curso	Este informe, README y cuaderno; relación con semanas 9–12
Algoritmo supervisado y comparación	KNN, SVM y MLP entrenados en tools/train.py
Preparación de imágenes	vision.py, sección 2 del cuaderno y gráfico
Red diseñada y arquitectura	MLP 64-64-32-10, explicación y diagrama en la aplicación
Entrenamiento, CV y ajuste	GridSearchCV estratificado de 3 pliegues sobre train
Evaluación test e interpretación	360 ejemplos UCI; 10 000 MNIST; límites explícitos
Matriz, precisión, recall y F1 con datos públicos	models/metrics.json, photo_metrics.json y cuaderno
Regresión, K-Means y MLP con datos ficticios	Sección 7 del cuaderno, CSV sintético y gráficos
Predicciones frente a etiquetas reales	docs/predicciones.png y salidas del cuaderno
Informe con decisiones y resultados	Este documento y cuaderno ejecutado
Esquema/diagrama alineado a la propuesta	docs/diagrama.svg, PNG, cuaderno y Cómo funciona
Preguntas guía	Sección 7 de este informe; sección 8 del cuaderno

11. Referencias

- Consigna PIAD-427_TRABAJOFINAL.pdf, proporcionada por la estudiante: caso, evidencias, preguntas y consideraciones. Se usa como referencia académica, separada de la autorización del usuario para publicar. - Material de semanas 9–10: Python, estadística, supervisado, redes, regresión y agrupación; semanas 11–12: OpenCV, grises y filtros. Referencias de aprendizaje; no se redistribuyen sus archivos. - UCI digits / sklearn: https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_digits.html - Redes MLP: https://scikit-learn.org/stable/modules/neural_networks_supervised.html - MNIST: https://www.tensorflow.org/datasets/catalog/mnist - Tesseract: https://tesseract-ocr.github.io/tessdoc/ImproveQuality.html - OpenCV: https://docs.opencv.org/4.x/d7/d4d/tutorial_py_thresholding.html - Render: https://render.com/docs/free ; https://render.com/docs/docker